

Проект: анализ датасета Steam Games

Исследование факторов популярности и разработка моделей
машинного обучения

Хабибулин Дамир
Григорьев Тимофей
Самароков Алексей

25 мая 2025 г.

- **Актуальность:**

- Игровая индустрия: огромный рынок, высокая конкуренция.
- Потребность в принятии решений на основе данных для разработчиков и издателей.

- **Цели нашего проекта:**

- Выявить ключевые факторы популярности и высоких оценок.
- Построить модели для предсказания:
 - Количества владельцев (Estimated owners) – **Регрессия**.
 - Уровня популярности игр – **Классификация**.

- **Источник:** Steam Games Dataset (Kaggle)
- **Первоначальный объем:** >111,000 игр.
- **Ключевые атрибуты:**
 - Estimated owners (Кол-во владельцев)
 - Peak CCU (Пик онлайн-игроков)
 - Price (Цена)
 - Metacritic score
 - Average playtime forever (Среднее время игры)
 - Genres, Categories

- **Другие атрибуты:** Required age, DLC count, Developers, Publishers, Achievements и др.
- **Качество данных:**
 - "Данные оказались настоящим вызовом, потребовавшим значительных усилий по очистке и подготовке."
 - Начальная проблема: смещение данных в ключевых столбцах.

Видим, что датасет просто балдеж. Без мата даже сложно описать мои эмоции и кол-во разных попыток это пофиксить. Ну ладно...

Рис.: Комментарии Дамира

Шаг 1: Наводим порядок

- **Удаление столбцов:** Удалено 19 нерелевантных/избыточных столбцов (ID, текстовые описания, ссылки и т.д.).
- **Пропущенные значения:**
 - Решение: `df.dropna()` (удаление строк с NaN).
 - Датасет сократился: 111 тыс. → 103 тыс. записей.

Шаг 2: Инженерия признаков

- Estimated owners:
 - Исходный формат: "0 - 20000"
 - Преобразование: 20000 (извлечение верхней границы, тип `int`).
- Windows, Mac, Linux:
 - Исходный формат: `True/False`
 - Преобразование: 1/0 (тип `int`).

Шаг 2: Инженерия признаков

- **Categories и Genres:**
 - Проблема: Множественные значения в строке.
 - Решение: One-Hot Encoding для топ-15 популярных значений.
 - Созданы новые бинарные признаки.
- **Фильтрация по Metacritic score $\neq 0$:**
 - Обоснование: Для задач, связанных с Metacritic.
 - Итоговый размер датасета для моделей: 3,958 игр.

Финальный взгляд на подготовленные данные


Резюме этапа: Данные очищены, признаки трансформированы.

Ключевые статистики :

	count	mean	std	min	25%	50%	75%	max
Estimated owners	3958.0	1.169591e+06	5.414543e+06	0.0	50000.000	200000.00	500000.00	2.000000e+08
Peak CCU	3958.0	1.530783e+03	2.245884e+04	0.0	1.000	7.00	67.00	8.721380e+05
Price	3958.0	1.530751e+01	1.210173e+01	0.0	7.475	13.49	19.99	6.999000e+01
Windows	3958.0	1.000000e+00	0.000000e+00	1.0	1.000	1.00	1.00	1.000000e+00
Mac	3958.0	3.888327e-01	4.875468e-01	0.0	0.000	0.00	1.00	1.000000e+00
Linux	3958.0	2.673067e-01	4.426097e-01	0.0	0.000	0.00	1.00	1.000000e+00
Metacritic score	3958.0	7.303638e+01	1.060782e+01	8.0	68.000	75.00	80.00	9.700000e+01
User score	3958.0	2.400202e-02	1.510030e+00	0.0	0.000	0.00	0.00	9.500000e+01
Positive	3958.0	1.244683e+04	1.059362e+05	0.0	223.000	926.50	4476.75	5.764420e+06
Negative	3958.0	1.671541e+03	1.459525e+04	0.0	60.000	196.00	733.00	7.666770e+05
Achievements	3958.0	3.313896e+01	5.507518e+01	0.0	8.000	25.00	45.00	1.448000e+03
Recommendations	3958.0	9.612369e+03	6.769783e+04	0.0	190.000	805.00	3740.25	3.441592e+06
Average playtime forever	3958.0	6.375958e+02	1.792277e+03	0.0	36.000	215.00	558.00	4.277300e+04
Average playtime two weeks	3958.0	9.879636e+01	5.995487e+02	0.0	0.000	0.00	0.00	1.099400e+04
Median playtime forever	3958.0	3.988651e+02	1.060141e+03	0.0	34.000	191.00	405.00	4.277300e+04

Шаг 3: EDA – Визуализация зависимостей: Корреляции

Корреляционная матрица:



Шаг 3: EDA – Цена vs. Количество владельцев

Зависимость количества владельцев от цены, оценки и времени игры:




Рис.: Цена vs. Количество владельцев

Шаг 3: EDA – Metacritic Score по жанрам

Распределение Metacritic Score по основным жанрам:




Рис.: Metacritic Score по жанрам

Шаг 3: EDA – Популярность игровых функций

Наиболее распространенные функции в играх:





Рис.: Популярность игровых функций

- *Выводы:* Single-player и Steam Achievements – наиболее частые.

Шаг 3: EDA – Парное распределение характеристик

Взаимосвязи между ценой, оценками и временем игры:

Парное распределение характеристик игр



Задача 1: Моделирование количества владельцев (Регрессия)

- **Цель:** Предсказать количество владельцев игры.
- **Метрики качества:**
 - RMSE (Корень из среднеквадратичной ошибки)
 - $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
 - R^2 (Коэффициент детерминации)
 - $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Подход 1: PCA + CatBoost

- **PCA (Метод главных компонент):** Снижение размерности до 5 компонент (после стандартизации).
- **CatBoost Regressor:** Градиентный бустинг.
- **Результаты:**
 - RMSE: 3,132,004
 - R^2 : 0.48
- **Вывод:** PCA не улучшил результат в данном случае.

Подход 2: Отбор признаков по важности

Важность признаков (определена CatBoost):




Рис.: Важность признаков для CatBoost Regressor

- **Gradient Boosting Regressor (sklearn):**
 - `n_estimators=100` на отобранных признаках.
- **Результаты:**
 - **RMSE: 1,376,930**
 - **R^2 : 0.90**
- **Вывод:** Лучшая модель для регрессии на данный момент!


Принцип работы Gradient Boosting

- **Аналогия:** Команда экспертов, где каждый учится на ошибках предыдущего.
- **Основные принципы:**
 - Ансамбль "слабых" моделей (деревьев решений).
 - Последовательное обучение: исправление ошибок предыдущей композиции.
- **Преимущества:** Высокая точность.

- **GridSearchCV:** Автоматический подбор гиперпараметров (`n_estimators`, `learning_rate`, `max_depth`).
- **Результаты на тесте (с лучшими параметрами):**
 - RMSE: 2,535,703
 - R^2 : 0.66
- **Вывод:** Результат ухудшился. Возможные причины: неудачная сетка параметров, специфика данных.

Задача 2: Классификация игр по уровням популярности

- **Новая задача:** Предсказание категории популярности (7 уровней).
- **Целевая переменная:** `Owner_Level` (создана с помощью `pd.cut`).
- **Модель:** CatBoost Classifier.
- **Метрика:** Accuracy.



Результаты классификации уровней популярности

- Accuracy (тест): 72.22%.

Матрица ошибок:




Рис.: Матрица ошибок для CatBoost Classifier

Другие интересные задачи (за рамками текущей реализации)

- Регрессия Peak CCU.
- Классификация Metacritic score > 75.
- Кластеризация по поведению игроков.

- **Предобработка:** Критически важна.
- **EDA выявил:** Сильную связь пикового онлайн и рекомендаций с кол-вом владельцев.
- **Регрессия (Estimated owners):** Gradient Boosting Regressor ($R^2 \approx 0.90$) – лучший.
- **Классификация (Уровни Estimated owners):** CatBoost Classifier (Accuracy $\approx 72\%$).
- **Важные факторы:** Отзывы, пик онлайн, F2P-модель, рекомендации.

Что дальше? Ограничения и перспективы

- **Ограничения:** Качество данных, не использованы текстовые данные.
- **Будущая работа:**
 - NLP-анализ описаний.
 - Глубокая инженерия признаков.
 - Исследование других моделей.